

Rocket 데이터셋 탐색적 데이터 분석(EDA) 보고서

이 보고서는 `rocket` 폴더에 있는 CSV 파일들을 분석한 결과를 담고 있습니다. 요구사항에 맞춰 `koreanize-matplotlib`을 사용하여 그래프의 한글을 처리했으며, `seaborn` 스타일은 사용하지 않았습니다.

1. events.csv 분석

사용자 행동 이벤트(조회, 장바구니 추가, 구매) 데이터를 담고 있습니다.

1.1. 데이터 샘플

timestamp	visitorid	event	itemid	transactionid
1433221332117	257597	view	355908	nan
1433224214164	992329	view	248676	nan
1433221999827	111016	view	318965	nan
1433221955914	483717	view	253185	nan
1433221337106	951259	view	367447	nan

1.2. 데이터 정보

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2756101 entries, 0 to 2756100
Data columns (total 5 columns):
#   Column          Dtype
---  -
0   timestamp       int64
1   visitorid       int64
2   event           object
3   itemid          int64
4   transactionid   float64
dtypes: float64(1), int64(3), object(1)
memory usage: 105.1+ MB
```

1.3. 기술 통계

	timestamp	visitorid	itemid	transactionid
count	2.756101e+06	2.756101e+06	2.756101e+06	22457.000000
mean	1.436424e+12	7.019229e+05	2.349225e+05	8826.497796
std	3.366312e+09	4.056875e+05	1.341954e+05	5098.996290
min	1.430622e+12	0.000000e+00	3.000000e+00	0.000000
25%	1.433478e+12	3.505660e+05	1.181200e+05	4411.000000
50%	1.436453e+12	7.020600e+05	2.360670e+05	8813.000000
75%	1.439225e+12	1.053437e+06	3.507150e+05	13224.000000
max	1.442545e+12	1.407579e+06	4.668670e+05	17671.000000

1.4. 결측치 확인

	결측치 수
timestamp	0
visitorid	0
event	0
itemid	0
transactionid	2.73364e+06

transactionid는 구매 이벤트에서만 생성되므로, 대부분의 행에서 결측치인 것은 자연스러운 현상입니다.

2. category_tree.csv 분석

상품 카테고리의 계층 구조(부모-자식 관계)를 나타냅니다.

2.1. 데이터 샘플

categoryid	parentid
1016	213
809	169
570	9
1691	885
536	1691

2.2. 데이터 정보

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1669 entries, 0 to 1668
Data columns (total 2 columns):
#   Column      Non-Null Count  Dtype
---  -
0   categoryid  1669 non-null   int64
1   parentid    1644 non-null   float64
dtypes: float64(1), int64(1)
memory usage: 26.2 KB
```

2.3. 기술 통계

	categoryid	parentid
count	1669.000000	1644.000000
mean	849.285201	847.571168
std	490.195116	505.058485
min	0.000000	8.000000
25%	427.000000	381.000000
50%	848.000000	866.000000
75%	1273.000000	1291.000000
max	1698.000000	1698.000000

2.4. 결측치 확인

	결측치 수
categoryid	0
parentid	25

최상위 카테고리는 부모 카테고리가 없으므로 `parentid`가 결측치일 수 있습니다.

3. item_properties.csv 분석

개별 상품의 속성(프로퍼티) 정보를 담고 있습니다. 두 개의 파일(`part1`, `part2`)을 병합하여 분석합니다.

3.1. 데이터 샘플

timestamp	itemid	property	value
1435460400000	460429	categoryid	1338
1441508400000	206783	888	1116713 960601 n277.200
1439089200000	395014	400	n552.000 639502 n720.000 424566
1431226800000	59481	790	n15360.000
1431831600000	156781	917	828513

3.2. 데이터 정보

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 20275902 entries, 0 to 20275901
Data columns (total 4 columns):
#   Column      Dtype
---  -
0   timestamp   int64
1   itemid      int64
2   property    object
3   value       object
dtypes: int64(2), object(2)
memory usage: 618.8+ MB
```

3.3. 기술 통계

	timestamp	itemid
count	2.027590e+07	2.027590e+07
mean	1.435157e+12	2.333904e+05
std	3.327798e+09	1.348452e+05
min	1.431227e+12	0.000000e+00
25%	1.432436e+12	1.165160e+05
50%	1.433646e+12	2.334830e+05
75%	1.437880e+12	3.503040e+05
max	1.442113e+12	4.668660e+05


3.4. 결측치 확인

	결측치 수
timestamp	0
itemid	0
property	0
value	0

결측치가 없는 것을 확인했습니다.

4. 데이터 시각화 및 심층 분석

4.1. 이벤트 유형 분포




가장 많은 이벤트는 'view'이며, 'addtocart'와 'transaction'이 그 뒤를 잇습니다. 이는 일반적인 이커머스 funnel 형태를 보여줍니다.

교차표: | event | 횟수 | |:-----|-----:| | view | 2.66431e+06 | | addtocart | 69332 | | transaction | 22457 |

4.2. 상위 20개 카테고리 (조회수 기준)

상위 20개 카테고리 (조회수 기준)




조회수가 가장 높은 상위 20개 카테고리입니다. 어떤 카테고리가 사용자들의 관심을 많이 끄는지 알 수 있습니다.

피봇 테이블: | categoryid | 조회수 | |-----:|-----:| | 1613 | 463474 | | 491 | 352296 | | 1120 | 224280 | | 1509 | 134288 | | 1277 | 107573 | | 642 | 95906 | | 1483 | 80625 | | 1167 | 79854 | | 1051 | 73016 | | 822 | 70493 | | 1404 | 64706 | | 256 | 59349 | | 1402 | 57923 | | 429 | 50739 | | 546 | 50317 | | 959 | 50112 | | 496 | 47918 | | 1147 | 47266 | | 1228 | 46711 | | 342 | 45288 |

4.3. 상위 20개 카테고리 (장바구니 추가 기준)

상위 20개 카테고리 (장바구니 추가 기준)




장바구니에 가장 많이 추가된 상위 20개 카테고리입니다. 이는 잠재적 구매 가능성이 높은 카테고리를 의미합니다.

피봇 테이블:

categoryid	장바구니 추가 횟수
1613	12370
491	9096
1509	5584
1120	4644
1277	3115
707	2869
822	1944
720	1878
1483	1867
47	1761
1051	1715
1404	1703
72	1699
959	1634
1228	1540
1167	1329
342	1283
256	1253
1385	1252
282	1146

4.4. 상위 20개 카테고리 (구매 완료 기준)


상위 20개 카테고리 (구매 완료 기준)



실제로 구매가 가장 많이 일어난 상위 20개 카테고리입니다. 이는 비즈니스의 핵심 수익원을 파악하는데 중요합니다.

피봇 테이블: | categoryid | 구매 완료 횟수 | |-----:|-----:| | 1509 | 2015 | | 1613 | 1994 | | 491 | 1528 | | 1120 | 900 | | 720 | 724 | | 72 | 661 | | 822 | 649 | | 707 | 648 | | 1277 | 637 | | 959 | 532 | | 1228 | 530 | | 1483 | 523 | | 1051 | 485 | | 256 | 425 | | 1385 | 424 | | 579 | 379 | | 1147 | 369 | | 47 | 360 | | 74 | 348 | | 618 | 336 |


4.5. 일별 총 이벤트 발생 횟수



시간에 따른 전체 이벤트 수의 추이를 보여줍니다. 특정 기간에 이벤트가 급증하거나 급감하는 패턴을 파악할 수 있습니다.

교차표 (상위 10일): | timestamp_dt | 이벤트 수 | |-----:|-----:| | 2015-07-26 00:00:00 | 32703 | | 2015-07-27 00:00:00 | 28562 | | 2015-07-25 00:00:00 | 27106 | | 2015-05-18 00:00:00 | 27084 | | 2015-07-14 00:00:00 | 26872 | | 2015-05-19 00:00:00 | 26799 | | 2015-07-13 00:00:00 | 26119 | | 2015-07-20 00:00:00 | 25332 | | 2015-07-08 00:00:00 | 25035 | | 2015-07-09 00:00:00 | 24997 |

4.6. 시간대별 총 이벤트 발생 횟수




하루 중 어떤 시간대에 사용자들이 가장 활발하게 활동하는지 보여줍니다. 마케팅 캠페인 시간 설정 등에 활용할 수 있습니다.

교차표: | hour | 이벤트 수 | |-----:|-----:| | 0 | 144303 | | 1 | 140702 | | 2 | 145879 | | 3 | 150860 | | 4 | 147184 | | 5 | 119572 | | 6 | 76972 | | 7 | 43944 | | 8 | 25309 | | 9 | 17909 | | 10 | 16408 | | 11 | 20330 | | 12 | 31486 | | 13 | 51089 | | 14 | 81823 | | 15 | 129092 | | 16 | 161784 | | 17 | 179651 | | 18 | 181200 | | 19 | 183348 | | 20 | 187919 | | 21 | 184297 | | 22 | 175956 | | 23 | 159084 |

4.7. 요일별 총 이벤트 발생 횟수

요일별 총 이벤트 발생 횟수




주중과 주말 중 사용자의 활동성에 차이가 있는지 파악할 수 있습니다.

교차표: | dayofweek | 이벤트 수 | | :-----|-----: | Monday | 439813 | | Tuesday | 447077 | | Wednesday | 431114 | | Thursday | 418761 | | Friday | 379699 | | Saturday | 305215 | | Sunday | 334422 |

4.8. 상위 20개 상품 속성(Property) 분포

상위 20개 상품 속성(Property) 분포




상품들이 어떤 종류의 속성을 가장 많이 가지고 있는지 보여줍니다. 'available', 'categoryid' 등이 많이 사용되는 것을 볼 수 있습니다.

피봇 테이블:

property	횟수	:	-----	:	-----	:	888	3.0004e+06	:	790	1.79052e+06			
available	1.50364e+06	:	categoryid	788214	:	6	631471	:	283	597419	:	776	574220	:
678	481966	:	364	476486	:	202	448938	:	839	417239	:	917	417227	:
159	417053	:	112	417053	:	227	347492	:	698	289849	:	451	264416	:
962	239372	:			:			:			:			:

4.9. 사용자별 이벤트 수 분포




대부분의 사용자는 적은 수의 이벤트를 발생시키며, 소수의 '헤비 유저'가 매우 많은 이벤트를 발생시키는 롱테일 분포를 보입니다.

피봇 테이블 (상위 10명):

visitorid	이벤트 수	:	-----	:	-----	:	1150086	7757	:	530559
4328	152963	:	3024	895999	:	2474	163561	:	2410	371606
684514	2246	:	892013	2024	:	861299	1991	:		

4.10. 상품별 이벤트 수 분포




사용자 분포와 유사하게, 대부분의 상품은 적은 수의 이벤트를 받으며, 소수의 인기 상품이 많은 주목을 받는 것을 알 수 있습니다.

피봇 테이블 (상위 10개):

itemid	이벤트 수
187946	3412
461686	2978
5411	2334
370653	1854
219512	1800
257040	1647
298009	1642
96924	1633
309778	1628
384302	1608

4.11. 시간대별 이벤트 심층 분석


시간대별 이벤트 유형 비교



모든 이벤트 유형(view, addtocart, transaction)이 비슷한 시간대 패턴을 보입니다. 새벽 시간(6-14시)에 활동이 저조하다가, 늦은 오후부터 새벽 3시까지 활발한 활동이 이어집니다.

피봇 테이블: | hour | addtocart | transaction | view | |-----:|-----:|-----:|-----:| 0 | 3725 | 1119 | 139459 | | 1 | 3578 | 1037 | 136087 | | 2 | 3337 | 1012 | 141530 | | 3 | 3266 | 836 | 146758 | | 4 | 3141 | 747 | 143296 | | 5 | 2786 | 747 | 116039 | | 6 | 1803 | 477 | 74692 | | 7 | 1028 | 278 | 42638 | | 8 | 540 | 106 | 24663 | | 9 | 399 | 70 | 17440 | | 10 | 306 | 57 | 16045 | | 11 | 389 | 84 | 19857 | | 12 | 647 | 103 | 30736 | | 13 | 1106 | 215 | 49768 | | 14 | 1844 | 455 | 79524 | | 15 | 3233 | 1138 | 124721 | | 16 | 4341 | 1621 | 155822 | | 17 | 5040 | 2000 | 172611 | | 18 | 4973 | 1907 | 174320 | | 19 | 5094 | 1891 | 176363 | | 20 | 5222 | 1817 | 180880 | | 21 | 4891 | 1829 | 177577 | | 22 | 4723 | 1600 | 169633 | | 23 | 3920 | 1311 | 153853 |

시간대별 전환율 분석




조회 → 장바구니 전환율: 사용자들이 가장 적게 활동하는 오전 8-10시 사이에 가장 높은 전환율을 보입니다. 이는 해당 시간대 사용자들이 뚜렷한 목적을 가지고 쇼핑할 가능성이 높음을 시사합니다. **장바구니 → 구매 전환율:** 이른 새벽(2-4시)과 오전(8-11시) 시간대에 구매 전환율이 높게 나타납니다. 특히 활동량이 적은 오전 시간대의 구매 결정력이 주목할 만합니다.

피봇 테이블 (전환율 포함): | hour | view_to_cart_rate | cart_to_transaction_rate | |-----:|-----:|-----:|-----:|

0	2.67	30.04
1	2.63	28.98
2	2.36	30.33
3	2.23	22.23
4	2.19	23.78
5	2.40	26.81
6	2.41	26.46
7	2.41	27.04
8	2.19	19.63
9	2.29	17.54
10	1.91	18.63
11	1.96	21.59
12	2.11	15.92
13	2.22	19.44
14	2.32	24.67
15	2.59	35.20
16	2.79	37.34
17	2.92	39.68
18	2.85	38.35
19	2.89	37.12
20	2.89	34.80
21	2.75	37.40
22	2.78	33.88
23	2.55	33.44

4.12. 야간 장바구니 사용자의 재방문 패턴 분석

재방문 소요 시간




밤에 장바구니에 상품을 담은 사용자들의 상당수가 1시간 이내에 다시 사이트를 방문하는 것을 볼 수 있습니다. 이는 장바구니에 상품을 담은 직후 다른 상품을 탐색하거나 구매를 결정하는 경향이 있음을 보여줍니다.

교차표:

revisit_time_bin	사용자 수
1시간 이내	18523
1-6시간	344
6-24시간	463
1-3일	322
3일 이상	629

재방문 시 첫 행동 유형

야간 장바구니 사용자의 재방문 시 첫 행동 유형



재방문한 사용자의 가장 흔한 첫 행동은 'view' 입니다. 이는 장바구니에 담은 상품과 연관된 다른 상품을 보거나, 다른 상품과 비교하는 행동으로 해석할 수 있습니다. 'addtocart'가 두 번째로 높은 것은 추가적인 상품을 장바구니에 담는 행동 패턴을 보여줍니다.

교차표: | next_event_type | 사용자 수 | |:-----|-----:| | view | 11643 | | addtocart | 4356 | | transaction | 4282 |